AI 전문가 양성을 위한「KB AI 엘리트 교육」과정

TxLens

마이데이터 거래내역 정규화·분류 + 패턴 탐지 에이전트

> "가맹점명을 못 묶으면 구독도 못 찾는다"



6주차 최종 발표 · 2026-10-17 (토)

한눈에 보기

TxLens: 거래내역 정규화·분류 + 패턴 탐지

- 마이데이터: 고객 동의로 여러 금융사의 거래내역을 한 앱에 모으는 제도 → 지출분석의 재료
- 제각각인 가맹점명 정리 + 카테고리 분류 → 그 위에서 구독·이상지출·이상거래 탐지
- LangChain 1.0 `create_agent` · LangGraph · Pydantic v2 · Streamlit
- 1부·2부·화면 4개·사람 교정까지 동작 확인 (테스트 384개)
- 정확도: 룰만 93% / LLM만 86% / 하이브리드 99% → 예상과 순서가 달랐음

해결하려는 현업 문제

아래 여섯 줄, 전부 같은 가맹점

```
  (주)스타벅스커피코리아 1234호점
  STARBUCKS  1234
스타벅스 강남역점
  NAVERPAY*스타벅스
  (주)에스씨케이컴퍼니     <-  법인명만 온다.  브랜드를 알 수 없다
  (주)케이지이니시스       <-  PG  경유.  실제 가맹점이 사라졌다
```

	내용
누가	지출분석 화면을 보는 고객 · 룰 사전을 관리하는 담당자
언제	거래내역이 들어올 때마다 (신규 브랜드·지점은 매일 생김)
왜 생기나	표준API가 필드 구조만 정하고 가맹점명은 사실상 자유 텍스트
결과 1	카테고리 오분류 → 지출분석 화면을 못 믿게 되고 안 쓰게 됨
결과 2	'기타' 증가 → 분석 가치 하락, CS 문의 증가
결과 3	사전 수작업 관리 → 새 표기가 계속 들어와 끝이 안 남

왜 룰만으로는 안 되는가

하나. 롱테일이라, 같은 룰도 세는 기준에 따라 93% vs 42%

룰 사전 v1 (head 29개) 로 측정	거래 건수 기준	정규화 키 기준
L2 정확도	93.0%	42.0%
미매칭	7.7%	58.7% (키 264개 중 155개)

둘. 표기 편차가 카드사·페이사별로 뭉쳐 있음 (실무 확인)

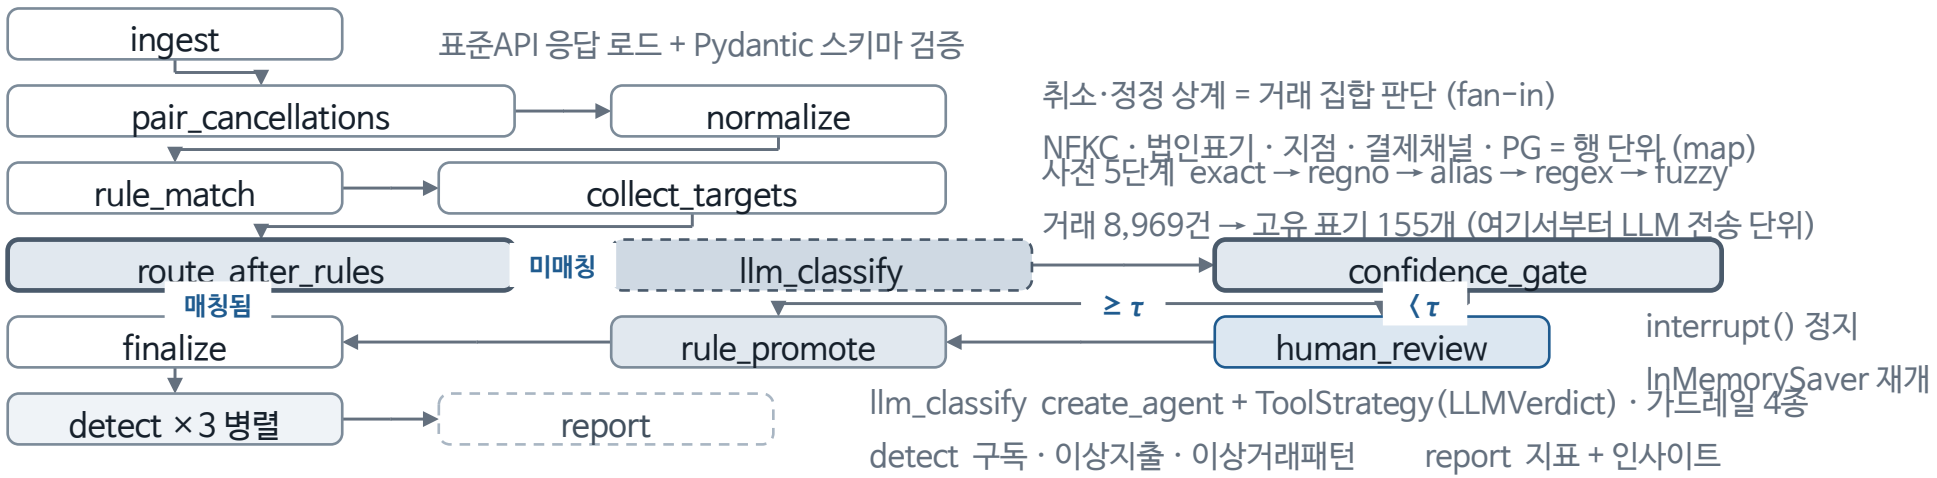
기관	비중	regno 채움	지배적 표기	난이도
A카드	30%	95%	브랜드명·지점명	쉬움
B카드	25%	50%	법인명 (브랜드 불명)	어려움
C카드	20%	20%	PG 노출 25%	매우 어려움
D페이	15%	35%	간편결제 프리픽스 70%	중간
E카드	10%	10%	전부 섞임, 오타 10%	매우 어려움

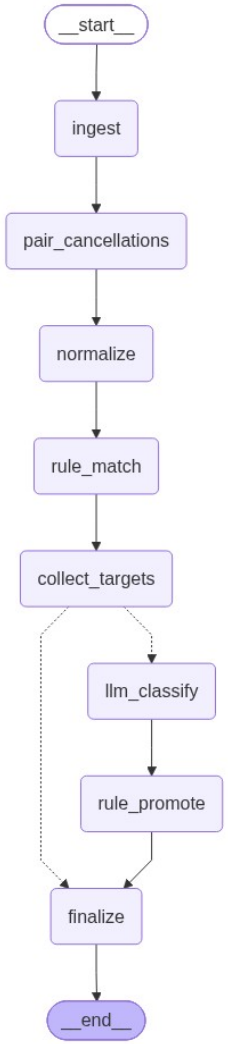
무엇을 하는 에이전트인가

1부가 이름을 묶어야 2부가 찾을 수 있음

	1부: 정규화·분류	2부: 패턴 탐지
입력	표준API 형태 거래내역	1부의 출력
방법	룰(head) + LLM(tail) + 사람 교정 → 사전에 반영	통계 규칙 (LLM 안 씀)
출력	`merchant_canonical` · L1/L2 카테고리 · 신뢰도	구독 목록 · 이상지출 알림 · 이상거래 알림
지표	정확도 · 미분류율 · LLM 호출 감소	precision / recall

기능 흐름도





실제 그래프 (C)

- 설계 노드 13개 중 LLM이 들어가는 건 `llm_classify` 하나. 나머지는 테스트로 고정
- 조건부 분기 2개(`route_after_rules`·`confidence_gate`), 사람 개입 1개, 사전으로 돌아오는 루프 1개
- 지금 실제로 컴파일되는 노드는 8개 (`rule_promote` 포함)
- `build_graph(review=True)`로 켜면 승격 자리에 사람 검토 서브그래프가 들어감
- 탐지 3종은 그래프 노드가 아닌 일반 함수 (`finalize` 결과를 받음)
  - 오른쪽 그림: `get_graph()` 출력 그대로
- **A/B/C 세 구성 모두 이 그래프 하나로 돎.** 바꾸는 건 사전과 분류기뿐

State 설계: 스키마는 TypedDict, 필드는 Pydantic

	선택	이유
상태 스키마 `TxState`	`TypedDict (total=False)`	노드는 바뀐 키만 반환. Pydantic을 스키마로 쓰면 갱신 때마다 전체 재검증 (8,969건 × 노드 8개)
필드 타입	Pydantic `BaseModel`	단계 간 계약: `RawTx` → `NormalizedTx` → `ClassifiedTx`. 단계마다 보장하는 게 타입에 드러남

reducer는 필드 성질에 맞춰 선택

성질	필드	reducer
다음 단계가 대체한다	`raw·pairings·normalized·matched·confirmed·metrics`	없음 (교체)
여러 노드·라운드가 덧붙인다	`review_queue·human_corrections·rule_proposals·llm_failed`	`operator.add`
표기 단위 결과를 합친다	`llm_results`	`merge_verdicts` (나중 값 우선)

- `llm_results` 키 = 정규화 표기 = 캐시 키

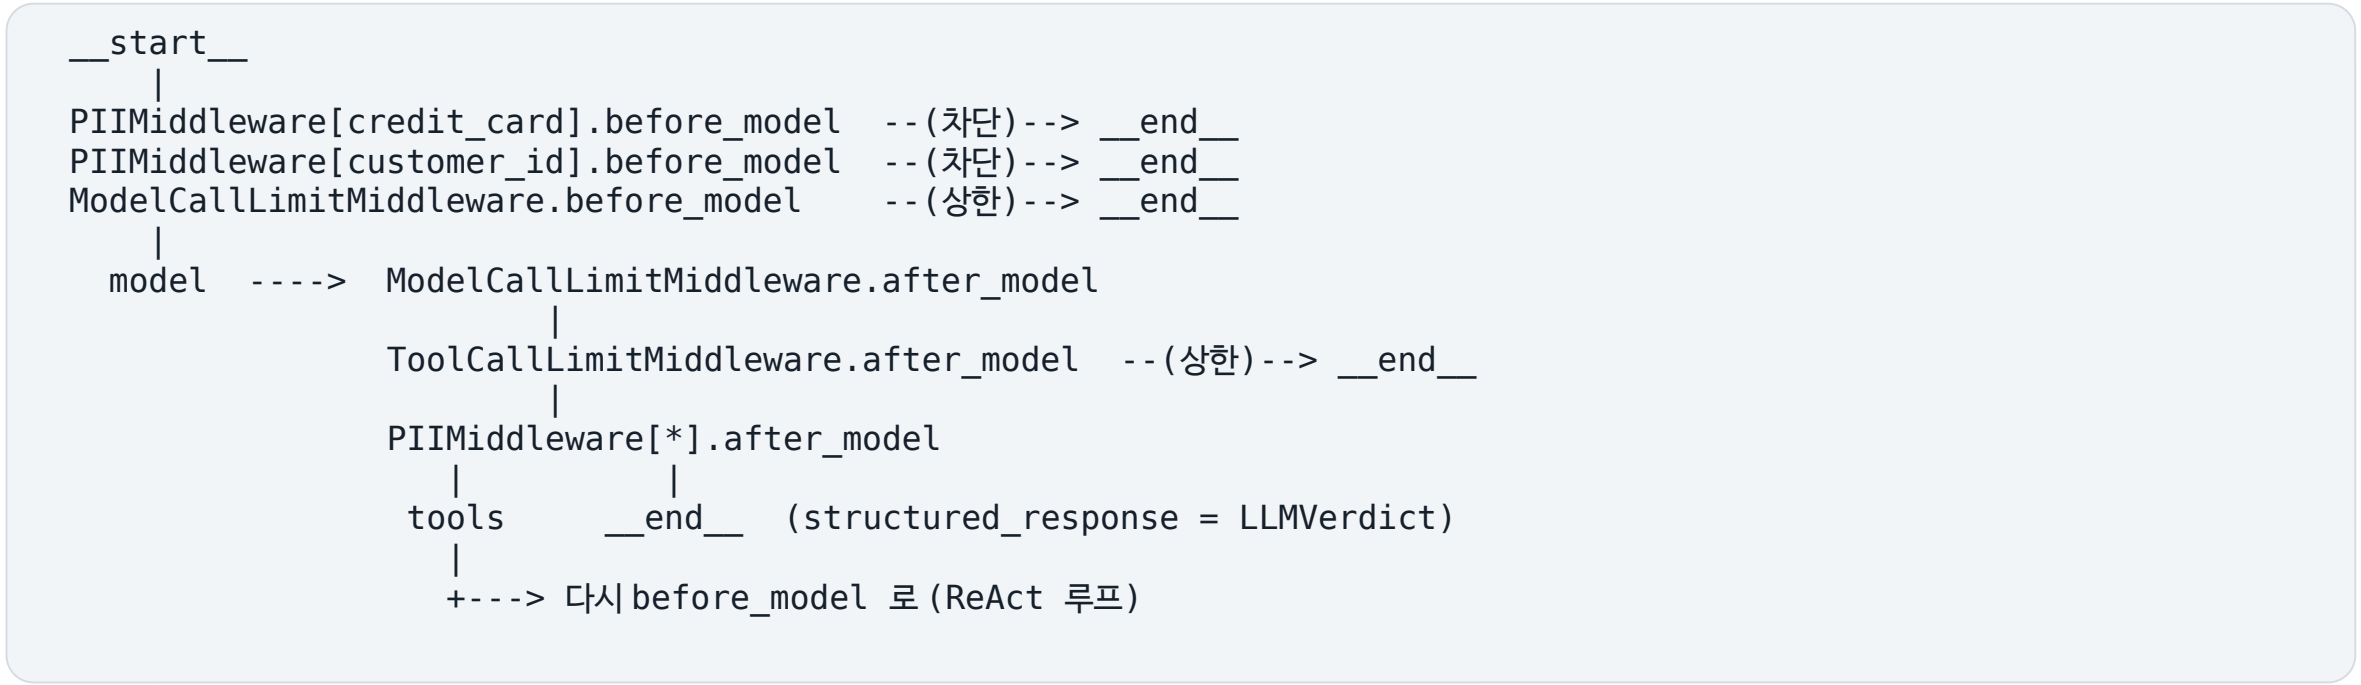
Node · Edge 설계: 어디서 나눌까

분리한 노드	근거
`preprocess` → `pair_cancellations` + `normalize`	앞은 (기관, 고객, 승인번호)로 묶어 합계를 보는 fan-in, 뒤는 행 단위 map
`rule_match` → `rule_match` + `collect_targets`	처리 단위가 거래 → 고유 표기로 바뀌는 지점. 여기서 LLM 비용이 정해짐

Edge: 조건부 분기 2개 + 일부러 안 만든 분기

- `route_after_rules`: 미매칭이 없으면 `llm_classify` 건너뜀
- `confidence_gate`: 신뢰도 τ 미만만 `human_review`로. **볼 게 없으면 사람을 안 부름**
- (A)는 `classifier=None`이라 그 노드와 분기 자체를 안 만듦
- Send로 표기별 병렬 처리는 안 함 (호출 수를 결정론으로 유지)

llm_classify 노드 안: 가드레일도 노드



- 가드레일 4종이 그래프 노드로 들어감: `PIIMiddleware` 2종 · `ModelCallLimit` · `ToolCallLimit`
- `model` ↔ `tools` 루프. 표기 155개에 모델 호출 587회
- **개인정보 차단은 프롬프트가 아닌 미들웨어에서**

Agent 입출력: 도구 3개 + structured output

입력: 사전을 프롬프트에 다 넣지 않고 도구로 조회

도구	하는 일	왜 도구인가
`lookup_alias`	별칭 사전 유사 조회 (`token_sort_ratio` ≥ 55)	사전이 커져도 프롬프트는 그대로
`search_taxonomy`	택소노미에서 후보 카테고리 검색	호출하면 더 정확 (을지로호프)
`get_brand_hint`	전처리 산출물 조회	이미 뽑은 값은 다시 추론 안 시킴

출력: response_format=ToolStrategy(LLMVerdict) 한 줄

막으려는 값	막는 장치
택소노미에 없는 카테고리	`CategoryL1·CategoryL2` Enum (자유 문자열 불가)
`l1=food` + `l2=cafe.coffee`	`model_validator` (실제로 나왔던 조합)
`confidence=1.7`	`Field(ge=0, le=1)`
근거 없는 판정	`reasoning·evidence` 필수 (검토자가 근거를 봐야 함)

도구를 밖으로: 사람과 에이전트가 같은 도구를 씀

내보낸 것: python -m txlens.mcp_server (stdio, 외부 네트워크 없음)

종류	무엇	쓰는 쪽
에이전트 도구 3종	`lookup_alias` · `search_taxonomy` · `get_brand_hint`	에이전트와 사람
사람용 도구 2종	`classify_merchant` · `dictionary_status`	사람만
리소스 2종	`txlens://taxonomy` · `txlens://dictionary`	붙여 읽는 자료

도구는 한 벌만 유지

- 기존 `make_tools()`를 감싸기만 함. 도구 설명도 같은 걸 쓰고, 둘이 같은지 테스트로 확인
- 실행 설정은 `.mcp.json` 한 곳. 외부 MCP 클라이언트와 우리 클라이언트가 같은 서버에 붙음

기본 실행 경로는 그대로 (전달 방식 때문에 수치가 바뀌면 안 되므로)

- `llm_classify`는 in-process 그대로. MCP 경유로 바꾸면 그래프를 async로 바꾸고 A/B/C를 다시 재야 함
- 대신 `mcp_server/client.py`로 **두 경로의 답이 같은지** 확인만 해 둠

기술 스택: 배운 걸 어디에 썼나

배운 기술 (LangChain 1.0 이후)	TxLens 에서 쓰는 자리	지금
`create_agent`	`llm_classify` 노드 안 (tail 분류만)	실측
`ToolStrategy(LLMVerdict)`	분류 출력 스키마	실측
`PIIMiddleware(strategy="block") ×2`	모델 호출 직전 차단	테스트
`ToolCallLimit·ModelCallLimit`	실행당 상한 `run_limit`	테스트
`AgentMiddleware.wrap_model_call`	호출 캐시 (히트면 모델 안 부름)	테스트
`InMemorySaver / InMemoryStore`	`human_review` 재개 / 룰 사전	실사용
`LLMToolEmulator` + 스크립트된 모델	API 키 없이 그래프 경로·툴 콜 순서 고정	384 tests
MCP `FastMCP` (stdio 서버)	에이전트 도구를 프로세스 밖으로	실사용
`langchain_mcp_adapters`	같은 서버에 우리 코드로도 붙어 답을 대조	테스트

LLM 을 쓰지 않는 곳을 먼저 정했다

- 문자열 정규화 · 표 생성 · 지표 계산 · JSON 변환 · 리포트 문장은 **전부 결정론 코드**

세 가지 구성 비교: 예상이 빗나간 곳

구성	거래 L2	키 L2	미매칭	확정 커버리지	LLM 키 / 모델 호출
(A) 룰만	93.0%	42.0%	7.7%	84.3%	0 / 0
(B) LLM만 (사전 없음)	85.6%	66.7%	5.1%	86.8%	257 / 1,026
(C) 하이브리드	98.9%	86.4%	1.6%	90.4%	155 / 587

- 예상: LLM만 쓰는 B가 제일 정확 → 실제로는 **룰만 쓴 A보다 7%p 낮음**
- B는 답을 많이 내지만 틀린 답도 자신 있게 냄 (쇼핑 500건을 식비로 분류)
- 같은 모델·프롬프트라도 하이브리드 안에서는 LLM 정확도 88% → 95%
- PG사 경유로 가맹점명이 지워진 8%는 어떤 구성으로도 못 품

사전 승격 루프: 자동은 별칭까지, 새 브랜드는 사람이

라운드	사전 키	LLM 표기	모델 호출	거래 L2	키 L2	자동 승격
1 · v1	65	155	572	98.0%	87.9%	35건
2 · v2	100	119	438	98.4%	90.5%	8건
3 · v3	108	111	394	98.1%	91.7%	1건
4 · v4	115	104	377	98.0%	90.2%	6건
5 · v5	121	98	351	97.7%	90.2%	3건

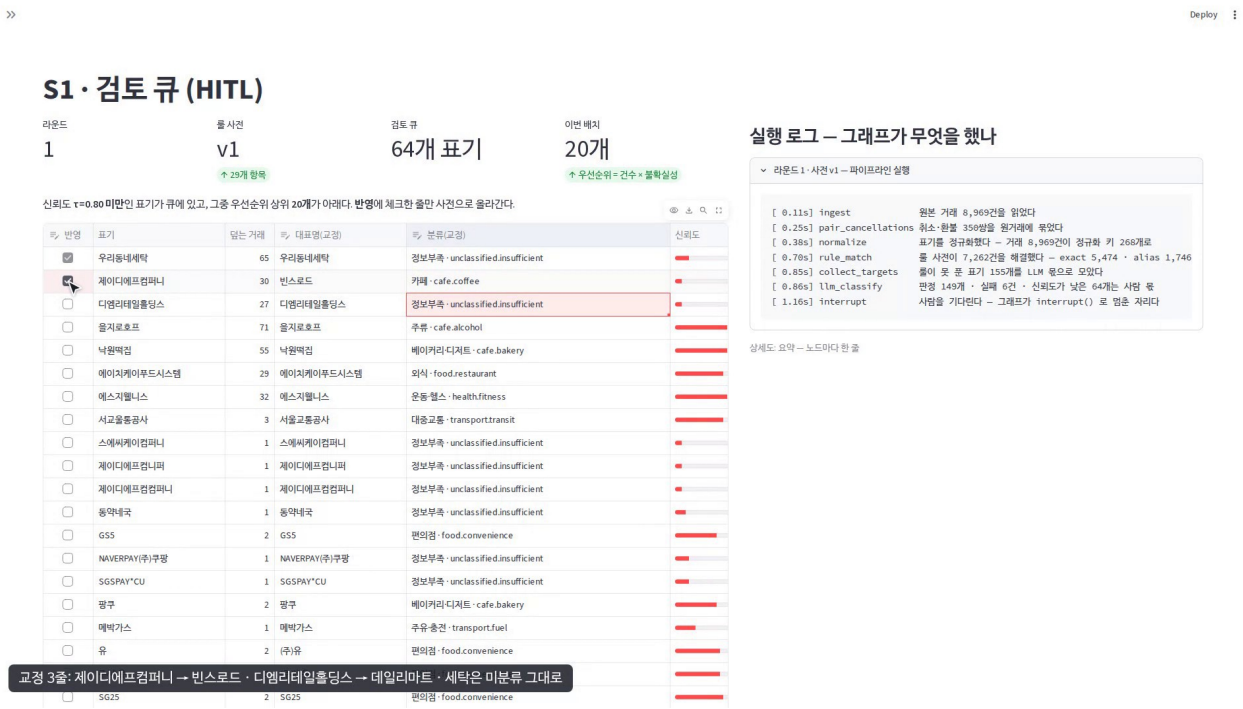
- 진짜 위험은 대표명. 타벅스가 새 브랜드로 굳으면 스타벅스가 둘로 쪼개짐 → 자동 승격은 아는 브랜드의 별칭만
- **5라운드 내내 수렴하지 않음.** 오타가 계속 새로 나옴 (GS2·GS5·GS52·GSS25…)
- 승격 판정은 거의 다 맞음 (1라운드 40건 중 39건 · 4~5라운드 13건 전부). 호출 39% 감소, 멈출 시점은 사람이 판단
- 검토 화면(S1)에서 세 줄 고치면 사전 29 → 32, 거래 122건 바로 반영, 다음 라운드 표기 155 → 115

2부 탐지: 분류가 좋아지면 탐지도 는다

분류 단계	미묶음	구독 P/R	이상지출 P/R	이상거래 P/R
정규화만 (사전·LLM 없음)	100%	95.3 / **56.2**	— / 0.0	96.4 / 79.4
(A) 룰만	15.7%	94.7 / 74.0	63.2 / 61.0	97.1 / 100.0
(C) 하이브리드	9.6%	94.7 / 74.0	62.5 / 67.8	97.1 / 100.0
정답 분류 (상한)	8.0%	95.7 / **90.4**	62.7 / 71.2	97.1 / 100.0

- 이름을 못 묶으면 구독은 절반(56%)만 잡힘. 넷플릭스가 표기 3개로 쪼개지는 식
- 이상지출은 0%, 이상거래는 79% 유지. 카테고리에 기대는 정도 차이
- 남은 구독 손실(74% → 90%)은 대부분 **사전이 잘못 묶은 것** (쿠팡와우 → 쿠팡)
- 일부러 심은 오탐 함정 60건 중 통과 0건
- 고객당 알림 월 0.6건 · 급증 정밀도 37%는 보수적으로 잡힌 값

화면으로 확인한 것



S1 검토 큐 · 왼쪽이 사람이 고치는 자리, 오른쪽이 8노드 실행 로그

- 영상 네 구간: S1 교정(1:08) → S4 토글(0:36) → S2 지표(0:24) → 준비 상태(0:08)
- 오른쪽 칸 로그가 그래프가 도는 증거 — 지연을 뺀 실제 노드 시간
- 라이브 아닌 녹화 · 스틸도 같은 영상에서 뽑아 덱과 어긋나지 않음
- 저장된 LLM 판정을 재생 — 데모 중 외부 호출 0

분류 결과를 어디에 남기나

지금은 메모리에만 있음

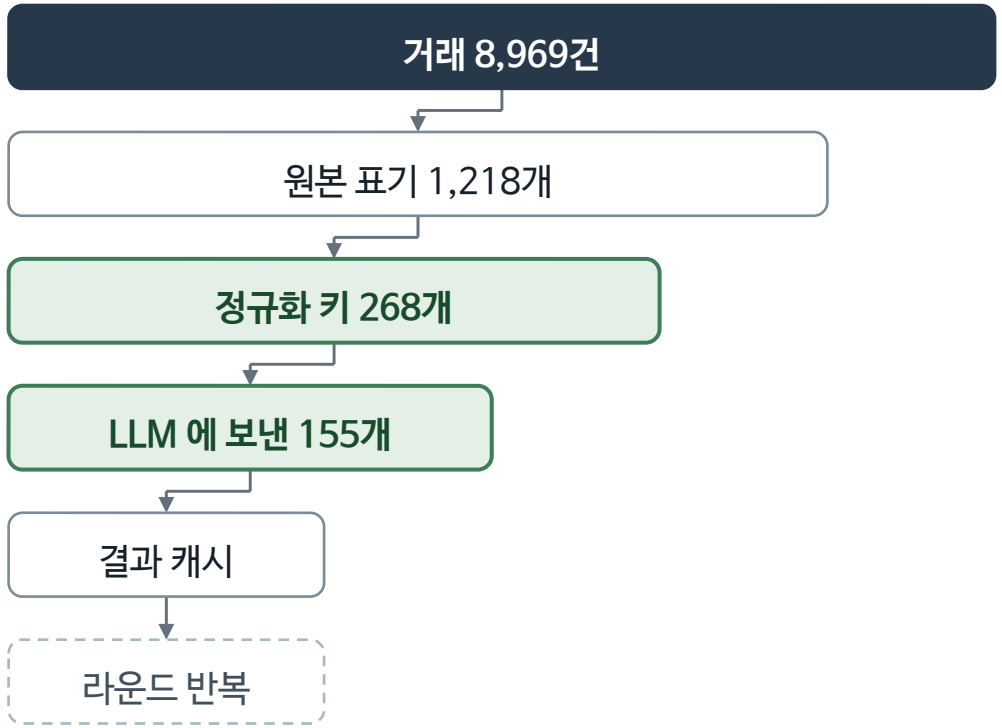
- 분류 결과 8,619건은 그래프 상태에만 있고 프로세스가 끝나면 사라짐
- **일부러 이렇게 함**: 시드만 같으면 재현되고 이전 실행의 영향을 안 받음

대신 남기는 것

무엇	어디에	왜
룰 사전 v{n}	`InMemoryStore` namespace `("rules","v{n}")` + `rules/v{n}.yaml`	승격 루프 결과. 버전 관리·롤백·감사 추적 필요
검토 큐와 스레드 상태	`InMemorySaver` (checkpointer)	`interrupt()`로 멈춘 곳에서 이어서 진행 (검토 화면에서 실제 사용)
거래별 분류 결과	남기지 않는다	사전이 원본이고 분류 결과는 파생물. 사전이 바뀌면 저장한 결과는 바로 낡음

- 남은 과제: 운영에서 매번 전량 재분류(약 33분)는 무리 → 사전 버전 기준 결과 캐시 검토

외부 호출은 거래의 1.7%, 쓸수록 줄어든다



합성 실측 · 고객 30명 × 6개월 · 시드 42

전처리 전 · 거래 대비 13.6%

전처리 후 · 실제 LLM 전송 단위 · 거래 대비 3.0%

룰 5단계가 head 를 덮고 남은 것 · 하이브리드 (C) 실측 · 거래 대비 1.7%

같은 키는 다시 보내지 않음 (히트는 승격 루프 2회차부터)

사전 성숙 → 외부 호출 감소 (0 은 아님) → 온프레미스 / sLLM 이전

- **비용**: 거래 8,969건에 외부 호출은 키 155개 — 전체의 **1.7%**
- **추세**: 승격 5라운드에 LLM 이 볼 표기 155 → 98, 호출 572 → **351** (−38.6%)
- **상한**: 호출 상한은 문서가 아니라 코드에 있다 — `run_limit` (S08)
- 실무 도입: 외부로 나가는 건 **가맹점명 문자열뿐** (미들웨어로 강제)

개발 과정: 1주차부터 오늘(6주차)까지

1~2주차 [완료]

주제 확정 · 기획 · 데이터 기반
블루프린트 · 택소노미 · 스키마 · 제공기관 프로파일 · 생성기 · 정답셋

3주차 [완료]

결정론 파이프라인 + 측정 (중간 발표 · 9/5)
ingest · preprocess (표기 1,218 → 키 268) · rule_match 5단계 · 평가 하네스
발표한 것: "룰만으로는 거래 93.0% · 키 42.0%"

4주차 [완료]

LangChain 1.0 Agent + 가드레일 + 메모리 + 승격 루프 + 2부 탐지
create_agent + ToolStrategy · 가드레일 4개 · (B) (C) 실측 · 실호출 5라운드 승격 53건
발표한 것: 가설 기각 · 승격 루프에 고정점 없음 · 2부 전이

5주차 [완료]

사람 교정(HITL) + 화면 + MCP · 여기서 발표 가능한 완성형
interrupt · human_review → 승격 · S1 교정 세 줄 → 거래 122건 즉시 반영
S2 는 그 자리에서 다시 잰다 (API 0) · 도구를 MCP stdio 서버로 프로세스 밖에

6주차 [오늘]

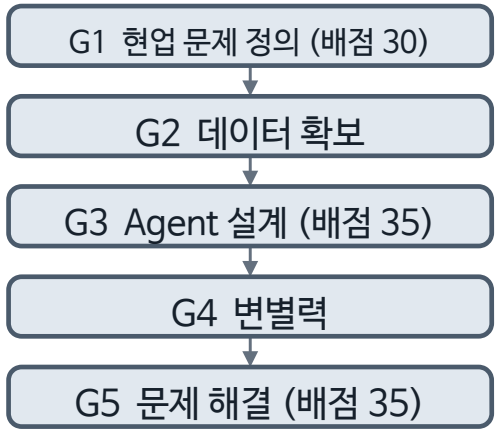
최종 발표 10/17 (10분 + Q&A · 데모 필수)
승격 루프에 고정점이 없음, 멈추는 건 사람 판단 · 데모는 화면 녹화로

컷 순서

미리 정해 둔 컷 순서: 모델 2단 escalation → S3 거래 탐색기 → 이상거래 후순위 → 골드셋 축소
일정이 안 밀려서 안 씀. S1 · S2 · S4 · 탐지 3종 · 룰 5단계 · 전이 실험 전부 들어감

부록 A. 주제를 어떻게 골랐나

후보 2안 → 게이트 5개



G2 는 신용정보법상 목적 외 이용 금지

통합자산 재무진단

○ 된다

× 실데이터 없이 성립 안 함

× 프롬프트 한 번으로도 됨

× 수강생이 가장 많이 고른다

× 좋았는지는 정성 평가

↓

기각
적합성 원칙·설명의무가 따라온다

TxLens 거래내역 정규화·분류

○ 된다

○ 표기 변형이라 합성으로 재현

○ 분기와 루프가 생긴다

○ 중복 가능성 낮음

○ 정확도·미분류율·호출수

↓

선정 (D-003)
직후 D-005 로 실데이터 미사용 확정

● 기준을 주제보다 먼저 정했다. 순서를 바꾸면 이미 마음에 든 주제에 유리한 기준을 나중에 만들게 된다.

● 재무진단을 접은 결정적 이유는 컴플라이언스다. 금융상품 추천이 들어가면 적합성 원칙과 설명의무가 따라온다. 6주 프로토타입이 감당할 범위가 아니다.

● 주제를 정하면서 제약을 하나 걸었다 (D-005). 실제 고객 데이터는 한 건도 쓰지 않고, 발표 자료에도 실데이터나 실화면 캡처를 넣지 않는다. 시드를 고정하니 재현이 되고, 생성기가 정답을 알고 있으니 라벨링 노동이 사라졌다.

부록 B. 설계 결정 18건

D-	결정	이유	버린 대안
003	주제 = 정규화·분류 + 탐지	실무 병목이고 수치화된다	통합자산 재무진단
004	룰/LLM 하이브리드 + 사전 승격	롱테일이라 역할 분담이 필연	LLM 전량 투입
005	실데이터 미사용, 합성 전용	신용정보법 목적 외 이용 금지	익명화 실데이터
006	Streamlit 을 발표 매체로	발표 수단을 컷 후보에 둘 수 없다	CLI 데모
010	탐지를 동등한 2부로	분류의 값을 탐지 숫자로 보인다	탐지를 부가 기능으로
012	제공기관별 편차 모델링	균일 랜덤은 군집 구조를 지운다	regno 를 주 키로
016	6주 커리큘럼 프레임에 일정을 맞춘다	중간 5분 / 최종 10분·데모 필수	2~3주 자체 일정
017	LangChain 1.0 표준 구성	배운 기술로 만들었음이 코드로 보여야 한다	레거시 체인·수동 파싱
018	제출 노트북 = 실행 프로그램	설계와 구현이 일치해야 한다	노트북에 로직 복사
024	룰 5단계 + 단계 0(PG)	확실한 신호가 애매한 신호에 덮이지 않는다	`token_set_ratio` (부분집합이 100점)
025	A/B/C 가 같은 그래프를 돈다	분류기만 바꿔야 비교가 성립한다	베이스라인마다 별도 스크립트
026	**실측이 가정 3건을 기각했다**	재보고 대신 가정을 고쳤다	유리한 해석으로 넘어가기
031	노드는 한 문장으로 끝나는 단위	한 노드가 두 일을 하면 경계가 설명이 안 된다	가짜 노드로 그림 늘리기
033	**자동 승격은 새 브랜드를 만들지 않는다**	사전이 판정의 검증자다. 대표명 오류가 2부로 전이된다	문턱만 낮춰 자동 승격 늘리기
037	HITL 은 **기본으로 꺼 둔다**	사람 없는 곳에서 멈추면 지표가 낮은 게 아니라 없어진다	항상 켜 두고 자동 승인
040	**화면은 결과가 아니라 과정을 보여준다**	8노드가 스피너 뒤에 있으면 설계는 말로만 남는다	`invoke` 하나 + 스피너
041	**화면의 수는 그 자리에서 다시 잰다**	적어 둔 수는 사전을 고친 날 화면만 낡는다	슬라이드 수치를 화면에 옮겨 적기
052	도구를 **MCP 서버로 내보낸다**	사람과 에이전트가 같은 질문을 던진다. 기본 경로는 그대로 (수치 불변)	사람용 도구를 따로 구현

● 나머지를 결정하는 건 D-004 다. LLM 을 런타임 분류기로 전량 투입하지 않는다. 근거는 부록 B-2.

부록 B-2. 설계 결정 — 왜 그렇게 정했나

● **D-026 은 이 판에서 새로 남긴 결정이고 셋이 다 내 예상과 반대였다.** ① 세탁소는 택소노미에 자리가 없어 모델의 "모른다"가 정답이었다 → 골드셋 라벨을 고쳤다. ② 택소노미 검색 도구를 막으면 싸질 줄 알았는데 정확도가 떨어졌다 → 되돌렸다. ③ (B) LLM만 이 (A) 룰만보다 정확할 줄 알았는데 11%p 낮았다 → 하이브리드의 논거가 오히려 강해졌다 (S12).

● D-012 를 균일 랜덤으로 하면 평가가 틀린다. 기관별 군집을 없애면 룰이 실제보다 불리해지고, 결과적으로 내 하이브리드가 실제보다 좋아 보인다. 내 주장에 유리한 데이터가 만들어지는 걸 막았다.

● **D-040·D-041 은 화면을 붙이면서 나온 결정이다.** 배점이 Agent 설계 구체성 35점인데 8노드가 `invoke` 하나 뒤에 숨어 있었다. 지표 화면도 마찬가지로, 슬라이드 수치를 옮겨 적으면 사전을 고친 날 화면만 옛 수를 말한다 — 그래서 되살릴 수 있는 줄은 화면이 그 자리에서 다시 잰다(7초 · API 0).

● D-017 은 이번 개정에서 새로 남겼다. 레거시 체인(`LLMChain`·`AgentExecutor`)과 수동 JSON 파싱은 쓰지 않는다. 무엇을 안 쓰는지 적어 두면 스택 선택의 범위가 분명해진다.

부록 C. 사전 승격 루프



측정 지표 (셋 다 내려가야 한다): 라운드별 LLM 호출 수 ↓ HITL 검토 큐 크기 ↓ 미분류율 ↓

설계

● 사전은 `InMemoryStore` 에 namespace (`"rules", "v{n}"`) 로 올려두고, 승격은 새 namespace 를 쓰는 방식으로 버전을 만든다. 파일(`rules/v{n}.yaml`)로도 떨어뜨려 롤백과 감사 추적을 남긴다. v2 의 머리말에 승격 조건·판정 모델·승격 목록(표기 → 대표명 · 덮는 거래 수)을 그대로 적는다.

● 검토 큐를 덮는 거래 건수 × (1 - confidence) 로 정렬한다. 한 건을 고치면 수백 건이 따라 고쳐진다.

● S1 화면이 교정 직후 "사전 v{n+1} 로 올라가서 거래 N건에 반영됐다"를 표시한다 — 붙였고, 실측이 세 줄 교정에 122건이다. 승격 루프가 없으면 이 화면을 만들 수가 없다.

● **폭주를 막는 장치가 층마다 다르다.** Agent 안(도구↔모델 왕복)은 `ToolCallLimit·ModelCallLimit`, 그래프는 사이클을 만들지 않는 것 자체가 장치이고, 라운드는 고정점 + 상한인데 실측에서는 상한이 걸렸다 — 수렴과 중단을 같은 말로 보고하지 않는다 (D-056).

부록 C-2. 승격 루프 실행 결과 (D-033 · D-056)

라운드	사전 키	LLM 표기	모델 호출	거래 L2	키 L2	자동 승격	멈춘 이유
1 · v1	65	155	572	98.0%	87.9%	35건	상한
2 · v2	100	119	438	98.4%	90.5%	8건	상한
3 · v3	108	111	394	98.1%	91.7%	1건	상한
4 · v4	115	104	377	98.0%	90.2%	6건	상한
5 · v5	121	**98**	**351**	97.7%	90.2%	3건	상한

● **멈춘 이유가 곧 결과다. 다섯 라운드 전부 상한이다 — 고정점이 아니다.** 올릴 후보가 매 라운드 남았다. 처음 보고한 "라운드 2 고정점"은 **저장된 판정을 재생한** 결과였고, 재생은 판정을 표기 이름으로 들고 있어 **다음 라운드가 커진 사전을 조회하지 못한다** (D-056).

● **승격이 틀려서 멈춘 게 아니다.** v4·v5 가 더한 13건은 정답셋 대조 **13/13 맞음**이고 `alias` 단계는 다섯 라운드 전부 **L2 100%** 다. 오타가 롱테일이라 **고치는 만큼 새로 나온다** — GS2·GS5·GS52·GSS25 가 라운드마다 하나씩 올라왔다.

● **그래서 확인된 값은 호출 감소다.** 표기 155 → 98(-36.8%) · 호출 572 → 351(-38.6%). **끝나는 자리는 고정점이 아니라 "남은 것은 사람 몫"이라는 판단**이고, 그 크기가 검토 큐 45 다.

● **거래 L2 하락(98.4 → 97.7)은 승격이 아니라 LLM 분산이다.** alias 는 100% 고 흔들린 것은 `llm` 단계(84.9 → 77.2%)다. 같은 사전 v3 을 두 번 실호출하니 판정 106개 중 같은 것이 **32개**, 대표명이 29개에서 달랐고 승격이 **1건 ↔ 7건**으로 벌어졌다 — **승격 수는 수렴의 증거가 아니다**.

● **문턱은 정답셋으로 골랐다.** 근거별 정밀도가 `brand_known` 95.9% · `keyword` 78.7% · `guess` 9.1% — 근거가 신뢰도보다 강한 신호다. 라운드 1 승격 35건은 키 단위 100% · 거래 단위 97.5%(39/40)이고 유일한 오답은 D-022 가 예고한 쿠팡/쿠팡와우다 — 그것이 라운드 3 에서 **실제로 사전에 굳었다**(HITL 의 표적 · D-035).

● 룰만(A) 구성도 v2 사전에서 키 L2 42.0 → **54.9%** 로 오른다. 승격의 값은 LLM 이 없는 경로에도 남는다는 뜻이다.

● **판정 실패가 라운드마다 2~5건** 난다 — 재생은 실패할 수 없어 드러나지 않던 현상이다.

부록 D. 분류와 탐지의 연결

원본 표기

NAVERPAY*스타벅스 · 스타벅스 강남역점 · ㈜에스씨케이컴퍼니

1부 정규화·분류

merchant_canonical = "스타벅스" · category = 카페/간식

구독 탐지

같은 canonical 로 묶여야
"주기 3회"가 채워진다

이상지출 탐지

카테고리가 맞아야
기준선(직전 3개월)이
맞게 잡힌다

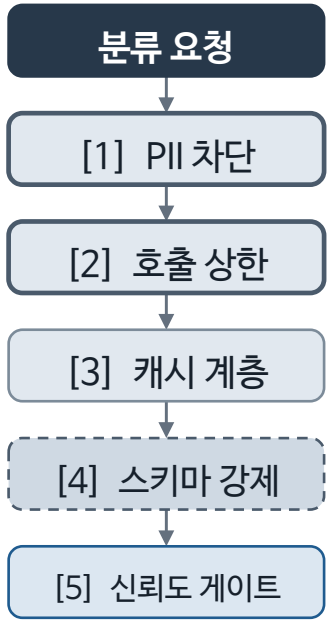
이상거래 탐지

같은 가맹점 판정이 맞아야
중복결제가 보인다

정규화가 안 되면 → 서로 다른 3개 가맹점 → 3회를 못 채움 → 구독을 놓친다
카테고리가 틀리면 → 기준선이 잘못 잡힘 → 이상지출 오탐이 늘어난다

"가맹점명을 못 묶으면 구독도 못 찾는다" → 전이 실험(부록 F)으로 확인한다

부록 E. 규제 제약과 가드레일



고유 가맹점명 문자열 하나

PIIMiddleware(strategy="block") — 고객식별정보 · 카드번호 · 계좌번호 패턴이면 모델에 닿기 전에 차단
민감 업종 차단 목록도 custom detector 로 같은 자리에 붙는다 (미결)
ToolCallLimitMiddleware · ModelCallLimitMiddleware — 라운드당 호출 상한
비용 상한을 문서가 아니라 코드로 고정한다

wrap_model_call — 같은 문자열은 모델을 부르지 않는다 (캐시 히트)

모델 호출 → ToolStrategy(LLMVerdict) — Enum 밖 카테고리는 검증에서 막힌다
실패 시 재시도, 억지 통과 없음

confidence_gate → 낮으면 사람에게 (interrupt)

	흔한 LLM 적용	TxLens
전송 단위	거래 건 (고객·금액·일시가 붙는다)	고유 가맹점명 문자열
개인 식별	가능	문자열만으로는 불가
차단 지점	프롬프트 규칙 (지켜지는지 알 수 없다)	미들웨어 (코드로 강제, 테스트 가능)
재전송	매번	캐시 히트로 0
장기 경로	외부 의존이 고정된다	사전 성숙 → 호출 0 → 온프레미스

부록 F. 베이스라인 실측 (전문)

베이스라인 3종 (1부)

구성	거래 L1	거래 L2	키 L2	확정 커버리지	미매칭	PG마스킹	LLM 키	모델 호출
(A) 룰만	93.0%	93.0%	42.0%	84.3%	7.7%	8.0%	0	0
(B) LLM만	89.2%	85.6%	66.7%	86.8%	5.1%	8.0%	257	1,026
(C) 하이브리드	99.0%	98.9%	86.4%	90.4%	1.6%	8.0%	155	587

단계별 기여 — 확정 단계는 어느 구성에서도 100% 다

단계	(A) 건수 / L2	(B) 건수 / L2	(C) 건수 / L2
`pg_masked`	691 / 100.0%	691 / 100.0%	691 / 100.0%
`exact`	5,474 / 100.0%	—	5,474 / 100.0%
`alias`	1,746 / 100.0%	—	1,746 / 100.0%
`regex · fuzzy`	7 · 35 / 100.0%	—	7 · 35 / 100.0%
`llm`	—	7,485 / **88.4%**	531 / **94.9%**
`unmatched`	666 / 9.9%	443 / 14.9%	135 / 48.9%

● `llm` 단계만 88.4% 와 94.9% 로 갈린다. 같은 모델, 같은 프롬프트, 같은 도구이고 차이는 앞에서 룰이 head 를 덮었는지 하나뿐이다. 하이브리드에서 정확도와 비용이 함께 개선되는 이유가 여기 있다.

● `unmatched` 가 맞은 몫은 룰의 성과로 볼 수 없다. 정답이 미분류 인 거래를 미분류로 둔 것이다 (택소노미에 자리가 없는 업종. D-026①). 지표 출력에 이 설명을 함께 찍어 오독을 막았다.

부록 F-2. 베이스라인 실측 — 무엇을 틀렸나 · 기관별

혼동 상위 — (B) 가 무엇을 어떻게 틀렸나

정답 → 예측	(B) 2026-08-31	(C) 2026-10-12
shopping → food	**500**	4
cafe → unclassified	243	**89**
food → unclassified	28	59
culture → unclassified	60	5
health → shopping	**0**	—

● **1위 오분류는 재현되고 꼬리는 재현되지 않는다.** 같은 구성을 다시 돌렸을 때 shopping → food 는 497 → 500 으로 그대로였지만 health → shopping 은 106 → **0**, culture → unclassified 는 111 → 60 으로 움직였다. 주장의 근거는 1위이고, 꼬리 숫자를 근거로 쓰면 안 된다 (D-048).

● **(C) 열은 2026-10-12 재실측이다** (D-063). (B) 는 08-31 이라 B↔C 는 아직 두 실행이 섞여 있지만, (C) 쪽 꼬리가 실행마다 어떻게 움직이는지는 이제 같은 표에서 보인다 — cafe → unclassified 가 34 → **89** 로 벌어졌다. (A) 는 룰만 쓰므로 결정론이고 (A)↔(B) 비교에는 이 문제가 없다.

제공기관 축 분해 — 프로파일(S03)이 지표에 그대로 나타났다 (D-012)

기관	건수	(A) L2 / 커버리지	(C) L2 / 커버리지	PG
CARD_A	3,033	95.7% / 94.0%	99.7% / 98.1%	1.0%
CARD_B	2,807	91.3% / 82.7%	98.1% / 89.6%	7.8%
CARD_C	752	93.4% / 67.2%	99.3% / 73.3%	26.2%
CARD_E	917	89.7% / 76.0%	98.1% / 85.2%	13.2%
EFIN_D	1,110	92.8% / 79.9%	99.0% / 86.4%	11.3%

부록 F-3. 분류 → 탐지 전이 실험 (전문)

분류 단계	구독 P/R	급증 P/R	고액 P/R	이상거래 P/R	알림/월
정규화만	95.3 / 56.2	—	—	96.4 / 79.4	0.2
(A) 룰만	94.7 / 74.0	35.7 / 34.5	89.7 / 86.7	97.1 / 100.0	0.5
(C) 하이브리드	94.7 / 74.0	36.4 / 41.4	90.3 / 93.3	97.1 / 100.0	0.6
정답 분류 (상한)	95.7 / 90.4	37.1 / 44.8	90.6 / 96.7	97.1 / 100.0	0.6

● 도구: `pytest` 로 결정론 단계 회귀 고정(384건 — 2부·HITL·화면·MCP·제출 노트북 포함). 수치는 하네스의 `RunMetrics` 로 쟀다 — LangSmith 는 코드에 붙이지 않았다(환경변수만 켜면 같은 그래프가 그대로 트레이싱된다).

부록 F-4. 비용 · 재현성 — 같은 구성도 수가 움직인다

● 전량 실행 모델 호출 1,613회(B 1,026 + C 587), **승격 루프 5라운드 2,549회**, 사전 점검·재실측 포함 약 6,400회, **합계 약 3.4 달러**(개산). 전량 1회가 약 31분, 승격 라운드 하나가 약 7분이다.

● `gpt-4o-mini` **단일 모델**이고 2단 escalation(mini → 4o)은 측정하지 않았다 — 컷 후보 1 (D-010). 모델을 바꾸면 수치가 바뀐다는 점을 한계로 명시한다.

● **같은 구성을 다시 돌려도 수가 움직인다.** (B) 를 2026-08-31 에 재실측했더니 거래 L2 가 82.0 → 85.6%(**±3.6pp**), 호출이 1,059 → 1,026 이었다. 1위 오분류는 재현되고 꼬리는 재현되지 않는다(부록 F-2). 그래서 표에 실행 일자를 적고, 주장을 꼬리 숫자에 걸지 않는다 (D-048).

● **(C) 도 같은 성질이다 — 2026-10-12 재실측 (D-063).** 거래 L2 98.9 → **97.9%**(-1.0pp), 호출 580 → **587**, "모른다" 9 → 15 · 판정 실패 6 → 7. 모른다가 늘면 그 거래가 `llm` 에서 `unmatched` 로 내려가(531 → 441 · 135 → 225) **커버리지가 90.4 → 89.4%** 로 같이 내려간다. **변동은 LLM 을 쓰는 구성 전부의 성질**이고 (B) 만의 문제가 아니었다. (A) 는 93.0% 로 완전히 재현된다 — 결정론이라 그렇다.

● **그 분산이 정확도만 흔드는 게 아니다.** 같은 사전 v3 을 두 번 실호출하니 판정 106개 중 같은 것이 32개뿐이고 대표명이 29개에서 달랐다. 그 결과 **승격이 1건 ↔ 7건**으로 벌어졌다 — 루프의 **종료 조건까지** 흔든다는 뜻이라 승격 수를 수렴의 증거로 쓰지 않는다 (D-056).

● (C) 에서 판정 실패 6건, "모른다" 9개, 검토 큐 64개(10-12 실호출은 7 · 15 · 64). 실패를 미분류 에 합치지 않고 따로 센다. 5주차에 이 64개가 사람 검토로 넘어간다.

● **승격의 호출 감소는 이제 실측이다.** 라운드 1~5 를 실호출로 돌려 표기 155 → 98, 호출 572 → 351(-38.6%)을 쟀다 — 합계 2,549호출·$1.3 개산(부록 C-2). 재생으로 보고한 "라운드 2 고정점"은 틀렸고, 다섯 라운드 전부 상한에서 멈췄다 (D-056).

● **그 과정에서 플래그 하나로 417호출을 날렸다.** 상한에서 멈추면 그 라운드의 승격은 사전 파일로 나가지 않는다(그 사전으로 잰 지표가 없으므로 의도된 동작). `--rounds 1` 로 돌려 승격 7건이 조용히 버려졌다 — 표가 그 사실과 되찾는 방법을 찍도록 고쳤다.

● 전량 실행에서 캐시 히트 0 — 라운드 1회라 재전송이 없다. 라운드를 이어 돌리면 저장된 판정 재생으로 호출 0 이 되지만, **재생으로 종료 조건은 판정하지 않는다** (D-056).

부록 G. 1~4주차 실측 결과

항목	실측값	의미
거래	8,969건	고객 30명 × 6개월 (2026-03-01~08-31), 시드 42
원본 표기	1,218개	전처리 **전**. 거래 대비 13.6%
정규화 키	268개	전처리 **후**. 실제 LLM 전송 단위. 거래 대비 3.0%
분류 대상	8,619건 / 키 264개	취소 상계 175 + 취소 거래 175 제외
PG 마스킹 정답	691건 = 8.0%	원리적 하한. **세 구성에서 모두 같다** → 정확도 상한 92%
룰 사전 v1	head 29개 · 5단계 + 단계 0(PG)	(A) 거래 L2 93.0% / 키 L2 42.0% (D-024)
베이스라인 (B) LLM만	거래 L2 85.6% · 호출 1,026	**(A) 보다 7.4%p 낮다.** 가설 기각 (D-026③) · 2026-08-31 재실측 (D-048)
베이스라인 (C) 하이브리드	거래 L2 98.9% · 호출 587	미매칭 7.7 → 1.6%. LLM 단계 94.9% · 10-12 실호출은 97.9% (D-063)
승격 루프	실호출 5라운드 · **고정점 없음**(전부 상한)	LLM 표기 155 → **98**(36.8% 감소) · 호출 572 → **351** · 사전 65 → 121키 (D-056)
자동 승격 판정	5라운드 53건	`alias` 단계 L2 **100%** · v4·v5 분 13건은 정답셋 **13/13**. 별칭만 올린다 — 새 브랜드는 사람 몫 (D-033)
룰 사전 v2	head 29개 + 자동 별칭 34개	(A) 룰만 구성도 키 L2 42.0 → **54.9%** 로 오른다
테스트	359 passed	ruff clean. HITL 28건 · S1 화면 16건 · S2 화면 16건

- 정답셋을 생성 시점에 함께 기록하도록 만들어서 수동 골드셋 라벨링이 필요 없어졌다.
- 원본 표기 1,218 과 정규화 키 268 은 다른 수다. 섞어 쓰면 감소폭이 틀어진다. 앞 판에서 전송 단위 감소를 86.4% 로 적었는데, 실제 전송 단위는 키라서 97.0% 다 (룰까지 거치면 98.3%).

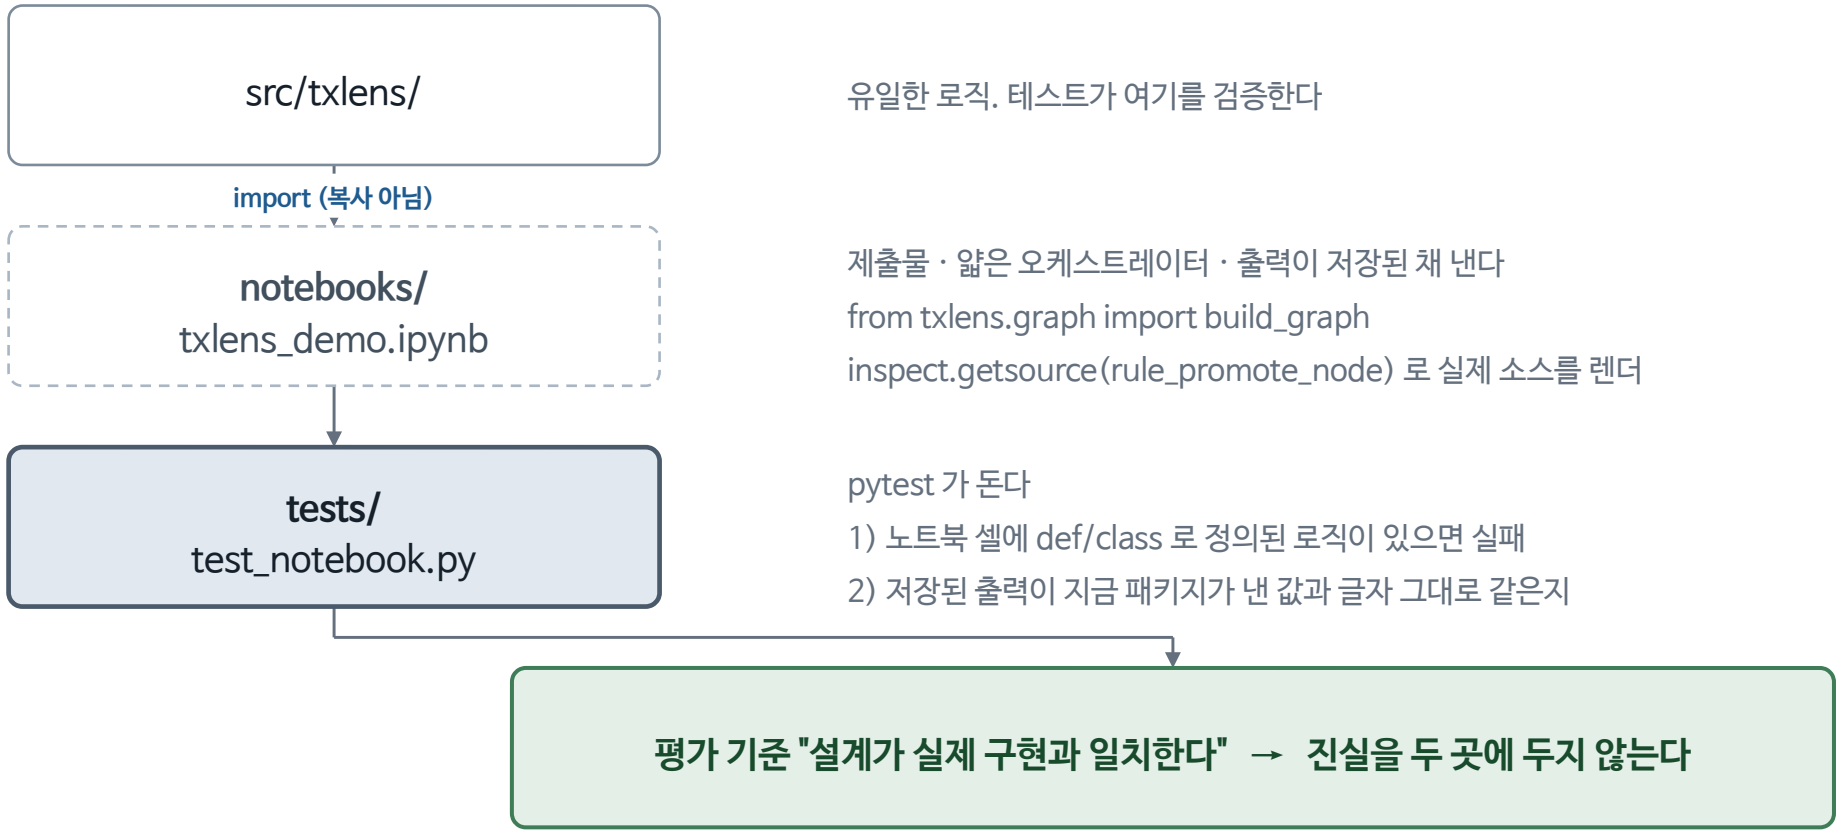
부록 G-2. 2부 실측 결과

항목	실측값	의미
구독 (정답)	90건 (탐지가능 73건)	연 구독 17건은 6개월 창에서 원리적으로 못 잡는다
구독 탐지	P 94.7 / R 74.0 (사전 v1)	상한(정답 분류)은 R **90.4**. 격차는 오귀속이다 (S14)
이상지출 (정답)	60건	급증 P 35.7 · R 34.5 / 단발 고액 P 89.7 · R 86.7
이상거래 (정답)	34건	P 97.1 · R **100.0** — 분류에 가장 덜 의존하는 탐지기다
오탐 함정	60건	구독처럼 보이는 비구독 30 + 정상 연속결제 30 — **통과 0건**
고객당 월 알림	0.5건	알림은 읽히지 않으면 없는 것과 같다 (blueprint §3.6)
전이 (구독 재현율)	56.2 → 74.0 → 90.4	정규화만 → 룰만 → 정답 분류. 표지의 주장 (S14)
프로파일 준수	regno 96/95 · 48/50 · 22/20%	제공기관별 회신율이 설계값대로 나왔다 (D-012)

● 정확도 목표를 절대치로 잡지 않았다. 미분류 8.0%가 하한이므로 **A→C 개선폭**(93.0 → 98.9%)과 전이 실험의 P/R 차이로 잡는다. 후자도 이제 실측이다.

● 탐지 3종은 LLM 을 호출하지 않는다. 같은 입력이면 같은 출력이고, 근거 문장이 규칙을 그대로 옮긴 문장이라 고객에게 설명할 수 있다 — 금융 앱에서 설명 가능성이 정확도보다 중요할 때가 있다.

부록 H. 최종 제출물 — 노트북과 실행 프로그램의 일치



부록 I. 한계와 위험

한계 / 위험	대응
합성 데이터라 실분포와 차이가 있다	한계로 명시한다. 기관별 편차는 실무 확인으로 모델링했고 오탐 함정도 넣었다
PG 마스킹은 못 푼다	억지로 추측하지 않고 미분류 + `pg_masked` 로 둔다. 상한 92%를 먼저 공개한다
5주차 과부하	컷 순서를 미리 정했다. 4주차 종료 시점이 이미 발표 가능선이다
라이브 데모 실패 (6주차 필수 항목)	**라이브로 하지 않는다** — 화면을 녹화해 두고 질문 시간에 틀며, 본편에는 스틸 한 장(S14-2)이 들어간다. replay 모드라 다시 뜰 수 있다. 남는 위험은 재생 환경 하나이고 H.264 · yuv420p · 무음은 녹화 스크립트가 검사한다 (D-053 · D-059)
`InMemoryStore` 는 프로세스가 죽으면 사라진다	사전은 파일로도 떨어뜨린다. 운영 전환 시 DB 백엔드 store 로 교체 (같은 인터페이스)
`gpt-4o-mini` 단일 모델로만 측정했다	2단 escalation 은 컷 후보 1 이다. 모델을 바꾸면 S12 의 수치가 바뀐다는 점을 한계로 명시한다
캐시 히트가 0 이었다	라운드 1회 실행이라 재전송이 없어서 당연하다. 캐시의 값은 승격 루프 2회차부터 측정된다 (부록 C)

부록 I-2. 미결 — 다음 작업

미결	상태
승격 루프가 수렴하지 않는다	실호출 5라운드가 전부 상한에서 멈췄다. 승격은 정답셋 대조 거의 전부 맞았고(1라운드 39/40 · 4~5라운드 13/13) 호출은 38.6% 줄었지만, 오타가 롱테일이라 후보가 계속 나온다. **어디서 멈출지는 사람이 정한다** — 자동 종료 조건을 더 두지 않는 것이 결론이다 (D-056)
S2 지표 화면의 (B) 줄	**해결.** (A)·(C)·전이·승격 라운드는 화면이 그 자리에서 다시 재는데 (B) 만 사전 없이 표기 전체를 보내는 구성이라 되살릴 수 없어, 2026-08-31 실호출 스냅샷(`--json data/gold/baselines-v1-gpt-4o-mini.json`, 1,026 호출)으로 읽는다 (D-041②). **다만 수가 움직였다** — 거래 L2 82.0 → 85.6%. 슬라이드는 화면이 읽는 이 수를 싣는다 (D-048)
자동 승격이 오답을 사전에 굳힐 위험	대표명을 사전에서 찾을 수 있을 때만 승격한다 — 사전이 검증자다 (D-033). 키 단위 100% · 거래 단위 97.5%, 유일한 오답은 D-022 가 예고한 쿠팡/쿠팡와우다
(C) 에서 판정 실패 7건 · "모른다" 15개	미분류 에 합치지 않고 따로 센다. 검토 큐 64개가 사람 검토로 넘어간다 — 10-12 실호출 기준이고 재실행마다 움직인다 (D-063)
급증 탐지의 정답셋이 성기다	※ 미결. 생성기가 심은 급증 중 여럿이 카테고리 월 합계를 움직이지 않는다(싼 브랜드의 건수만 늘려서) — 정밀도 37%는 하한이다. 문턱을 정답셋에 맞춰 구부리지 않고 제품 관점(1.5배 + 10만원)으로 정했다. 생성기 수정은 결국 하지 않았다 — 지금 데이터를 다시 만들면 이 문서의 1부 실측이 전부 바뀐다 (부록 F-3)
구독 탐지의 남은 손실이 커버리지가 아니다	74.0 → 90.4 의 격차는 사전이 **잘못 묶은 것**이다(쿠팡와우→쿠팡). 사람 교정의 표적을 여기로 잡았다 (S14)
가맹점명 자체의 추론 위험	※ 미결. 특정 병원·종교시설 이름은 그 자체로 민감정보 추론 단서가 될 수 있다. `PIIMiddleware` 의 custom detector 로 민감 업종을 차단하는 방안을 검토 중이나, 업종 목록의 기준은 판단이 필요하다
주차 간격이 균일하지 않다 (중간 9/5 → 최종 10/17, 달력 6주)	토요일 하루 수업이고 사이에 비수업 주가 있다. 4·5주차 강의일은 아직 확인하지 못했다. 달력 여유가 커리큘럼 주차보다 길어 버퍼로 썼다 — 안 밀려서 컷 순서는 쓰지 않았다

부록 J. Q&A — 설계·기술

질문	답
룰만 잘 만들면 되지 않나	그게 (A) 입니다. 거래 기준 93.0% 인데 정규화 키 기준은 42.0% 입니다. 건수로 보면 되는 것처럼 보이고 종류로 보면 절반이 안 됩니다. 그게 롱테일이고, 신규 브랜드가 계속 들어와 유지보수가 끝나지 않습니다
LLM 에 전부 넣으면 더 정확하지 않나	측정해 봤고 더 부정확했습니다. (B) 85.6% 대 (A) 93.0% 입니다. 커버리지는 (B) 가 높은데 정확도가 낮습니다. 답을 더 많이 내지만 그만큼 오분류가 늘어납니다. 하이브리드는 98.9% 이고 호출은 (B) 의 절반입니다
왜 (B) 가 (A) 보다 낮은가	사전이 없으면 법인명을 풀지 못합니다. 에스씨케이컴퍼니 200건이 그렇습니다. 편의점·마트도 식비로 500건 보냈습니다. 오분류가 계통적으로 몰립니다. 룰이 앞에서 head 를 덮으면 같은 모델의 LLM 단계 정확도가 88.4 에서 94.9 로 올라갑니다
(C) 의 unmatched 가 45.5% 나 맞았다는 건 뭔가	정답이 미분류 인 거래를 미분류로 둔 것이 맞은 겁니다. 룰의 성과가 아니라 택소노미에 자리가 없는 업종입니다. 성과로 읽히지 않게 지표 출력에 문장을 붙여 뒀습니다 (부록 F)
그럼 사전을 계속 키우면 LLM 이 필요 없지 않나	줄기는 하지만 0 이 되지는 않습니다. 실호출 5라운드에 호출이 39% 줄었지만 오타·신규 브랜드가 계속 들어와 한 번도 저절로 멈추지 않았습니다. 남는 tail 은 사람 몫이고, 호출이 충분히 줄면 온프레미스·sLLM 으로 옮길 수 있습니다 (D-056)
임베딩이나 파인튜닝은 왜 안 쓰나	학습 데이터에 라벨이 필요하고, 그 라벨을 만드는 게 지금 푸는 문제입니다. 승격 루프가 라벨을 쌓으니 그 다음 단계입니다
PG 마스킹은 어떻게 푸나	못 풉니다. 억지로 추측하면 오분류가 늘어 신뢰를 잃습니다. 미분류 로 두고 상한 92%를 먼저 공개합니다
FDS 와 뭐가 다른가	FDS 가 아닙니다. 차단이 아니라 확인해 보라는 알림이고 판단은 고객이 합니다

부록 J-2. Q&A — 승격 루프와 폭주 방지

질문	답
무한루프는 어떻게 막나	층마다 다른 장치입니다. Agent 안의 도구↔모델 왕복은 `ToolCallLimit·ModelCallLimit`, 그래프는 사이클을 만들지 않는 것 자체가 장치(DAG), 승격 라운드는 고정점이 종료 조건이고 라운드 상한은 안전핀입니다. **실측에서는 다섯 라운드 전부 상한이 걸렸고, 그래서 표에 "수렴 아님"이라고 적었습니다** — 안전핀이 실제로 일을 한 경우입니다 (D-056)
승격 루프를 왜 그래프 사이클로 안 만들었나	같은 실행에서 되돌면 LLM 이 잡은 거래가 다음 바퀴에 `exact` 로 재분류돼 단계 분포가, 즉 비교표가 흔들립니다. 그래프는 DAG 로 두고 루프는 라운드 사이(v1 → 승격 → v2 → 재측정)에 뒀습니다
자동 승격이 오답을 사전에 굳히면 어떻게 되나	그게 제일 큰 위험이라 자동은 **별칭까지만** 합니다. 대표명을 사전에서 찾을 수 있을 때만 올리므로 사전이 검증자입니다. 다섯 라운드에서 `alias` 단계는 늘 L2 100% 였습니다. 다만 **예고해 둔 쿠팡/쿠팡와우가 라운드 3 에서 실제로 굳었습니다** — 그 한 건이 HITL 이 먼저 볼 자리입니다 (D-033·D-056)
문턱 0.95 에서 0건이었으면 그냥 낮추면 되지 않나	낮출 수는 있는데 **얼마로** 낮출지가 근거 없는 숫자가 됩니다. 그래서 155개를 전수 판정해 저장하고 문턱별로 정답셋과 대조했습니다. 판정을 저장해 뒀으니 문턱 재실험은 이제 모델 호출 0회입니다
승격했는데 정확도가 떨어지면	그건 자동 승격이 오답을 굳혔다는 신호이고, 표에 거래 L2 를 함께 찍는 이유입니다. 이번에는 98.9 → 99.0 으로 떨어지지 않았습니다. 떨어졌다면 되돌립니다 — `rules/v{n}.yaml` 이 그래서 파일로 남습니다

부록 J-3. Q&A — Agent 구성과 도구 경계

질문	답
파이프라인인데 왜 Agent 인가	파이프라인 골격은 `StateGraph` 로 짜고, Agent 는 `llm_classify` 노드 안에만 둡니다. tail 분류에서 사전·택소노미를 조회하는 툴 콜이 실제로 필요합니다
왜 `SqliteSaver` 가 아니고 `InMemorySaver` 인가	데모와 노트북 재현성에는 InMemory 가 맞습니다. 프로세스를 넘겨야 하면 같은 인터페이스로 DB 백엔드로 바꿉니다. 사전은 별도로 파일에 떨어뜨립니다
MCP 를 왜 붙였나 — 억지로 끼운 것 아닌가	이미 어긋나 있던 자리를 골랐습니다. 에이전트 도구가 답하는 질문이 승격 루프에서 사람이 던지는 질문과 같은데, 코드는 `llm_classify` 안에만 있었습니다. 도구를 두 번 만들지 않으려고 `make_tools()` 를 감싸기만 했습니다 (S10 · D-052)
MCP 를 붙였는데 왜 수치가 안 움직이나	기본 분류 경로를 MCP 로 바꾸지 않았습니다. MCP 도구는 async 전용이라 그래프를 async 로 올려야 하고, 전달 방식이 바뀌면 A/B/C 표를 다시 재야 합니다 — 같은 구성을 다시 돌려도 수는 움직입니다 (D-048). 경로는 열어 두고 양쪽 답이 같은지는 테스트가 봅니다

● **부록 J 에서 네 행을 여기로 옮겼다.** 같은 표에 두면 슬라이드가 축소 바닥에 가까워진다 (뒷줄에서 못 읽는다 — D-034). 나누는 기준은 "에이전트를 어떻게 구성했나"다.

부록 K. Q&A — 실무·평가·범위

질문	답
실무에 정말 쓸 수 있나	외부로 나가는 건 가맹점명 문자열뿐이고 미들웨어로 강제합니다. 사전이 자라면 외부 호출이 줄어(5라운드 −39%) 온프레미스·sLLM 이전이 쉬워집니다. 0 이 되지는 않습니다 (부록 E · D-056)
가맹점명도 개인정보 아닌가	문자열만으로는 특정 개인을 식별할 수 없고, 정규화 키 단위라 거래 맥락과 분리됩니다. 다만 민감 업종명은 추론 단서가 될 수 있어 차단 방안을 검토 중입니다
합성 데이터로 한 실험이 의미가 있나	한계입니다. 다만 이 문제의 본질이 표기 변형이라 합성으로 재현되는 부분이 크고, 기관별 편차는 실무 확인으로 모델링했고 오탐 함정으로 precision 을 재게 했습니다
정확도 목표가 몇 %인가	절대치로 잡지 않습니다. 미분류 8.0%가 하한이고, 실측 개선폭이 A 93.0% → C 98.9% 입니다. 그게 탐지로 얼마나 전이되는지도 쟀습니다 — 구독 재현율 56.2 → 90.4 입니다 (S14)
가설이 틀렸는데 그대로 발표하나	그대로 발표합니다. 기각된 방향이 결과적으로 설계를 뒷받침합니다. 유리하게 해석하는 대신 골드셋 라벨과 프롬프트를 고쳤고 결정으로 남겼습니다 (D-026)
1부를 잘하는 게 왜 중요한가	표로 답합니다. 같은 탐지기를 이름만 정규화한 결과 위에서 돌리면 구독을 56.2%밖에 못 찾고 이상지출은 아예 0%입니다. 분류가 완벽하면 90.4%입니다. 1부는 목적이 아니라 2부의 전제입니다 (S14)
다른 팀과 차별점은	사전 승격 루프입니다. 실호출 다섯 라운드에 LLM 이 볼 표기가 155 → 98, 호출이 572 → 351 로 줄었습니다. 그리고 **멈추지 않았습니다** — 오타가 롱테일이라 어디서 끝낼지는 사람이 정합니다 (S13)
사람 교정으로 무엇을 먼저 고치나	커버리지가 아니라 **오귀속**입니다. 구독 재현율 74.0 → 90.4 의 격차가 전부 사전이 잘못 묶은 것(쿠팡와우→쿠팡)에서 나옵니다. 검토 큐 정렬에 이걸 반영합니다 (S14)
사람이 얼마나 붙어야 하나	숫자로 답합니다. 자동 승격 53건 뒤에도 표기 98개가 남고 검토 큐는 45개입니다. 큐는 덮는 거래 건수 × `(1 - confidence)` 로 정렬합니다 — 한 건을 고치면 수백 건이 따라 고쳐집니다
6주에 다 되나	4주차 종료 시점이 이미 발표 가능선이고 컷 순서를 미리 정했습니다 (S17)
코드는 어떻게 제출하나	GitHub Public Repo URL 과 노트북 둘 다 냅니다. 노트북은 패키지를 import 하는 얇은 층이라 실행 프로그램과 어긋나지 않습니다 (부록 H)

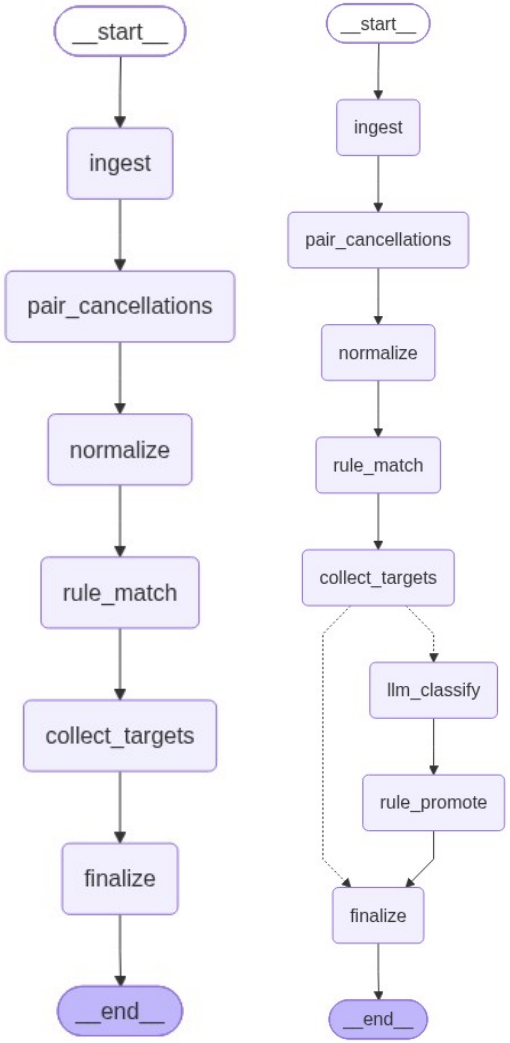
부록 K-2. Q&A — 지속가능성 · 비용 · 관측

질문	답
LLM 호출이 과한 건 아닌가	수로 답합니다. 거래 8,969건에 외부로 나간 건 **정규화 키 155개 · 모델 호출 587회**, 거래 대비 **1.7%** 입니다. 호출을 줄이는 게 설계 목표였고 그래서 룰 5단계가 LLM 앞에 섭니다 — 룰이 head 를 덮고 LLM 은 tail 만 봅니다 (S16)
사전이 커지면 호출도 늘어나지 않나	반대입니다. 실호출 5라운드에 LLM 이 볼 표기가 **155 → 98**, 호출이 **572 → 351 (−38.6%)** 로 줄었습니다. 다만 **고정점은 오지 않았습니다** — 오타가 롱테일이라 어디서 멈출지는 사람이 정합니다 (S13 · D-056)
많이 부르면 더 정확해지지 않나	그 가설로 시작했고 **기각됐습니다.** LLM 만 쓴 (B) 는 호출 1,026회에 거래 L2 **85.6%**, 룰만 쓴 (A) 는 호출 **0회**에 **93.0%** 입니다. 하이브리드 (C) 가 587회에 98.9% 로 가장 좋습니다 — 비용과 정확도가 같이 좋아졌습니다 (S12)
Langfuse 같은 관측 도구는 왜 안 붙였나	필요한 수를 코드가 이미 셉니다. `RunMetrics` 가 `llm_targets·llm_model_calls·llm_cache_hits`·단계별 카운터를 **정확도(`EvalResult`)와 분리해** 기록하고, 시드가 같으면 대시보드 없이 재현됩니다. 비용을 고쳐도 정확도 표가 오염되지 않게 **일부러 두 객체로 나눈** 설계입니다. 발표 직전에 측정 경로를 둘로 늘리면 **두 경로가 서로 다른 수를 말할** 위험이 있고, 그 비용은 이미 한 번 치렀습니다 (D-063). LangSmith 는 환경변수만 켜면 같은 그래프가 그대로 트레이싱됩니다 — 코드 변경 없이 열어 둔 자리입니다 (D-064②)
비용은 얼마인가	`gpt-4o-mini` 기준 전량 실행이 모델 호출 1,613회(B 1,026 + C 587)이고 승격 루프 5라운드가 2,549회입니다. 달러가 아니라 **호출 수**로 적는 이유는 모델 단가가 바뀌어도 설계 판단이 안 흔들리기 때문입니다 (부록 F-4)
캐시 히트가 0 인 건 안 돌았다는 뜻인가	설계대로입니다. `wrap_model_call` 캐시는 같은 키를 두 번 보낼 때 듣는데, 한 라운드는 각 키를 **한 번만** 보냅니다. 히트는 라운드 2회차부터 생기고, 그 전까지 0 인 게 맞습니다

부록 N. 실제 컴파일되는 그래프

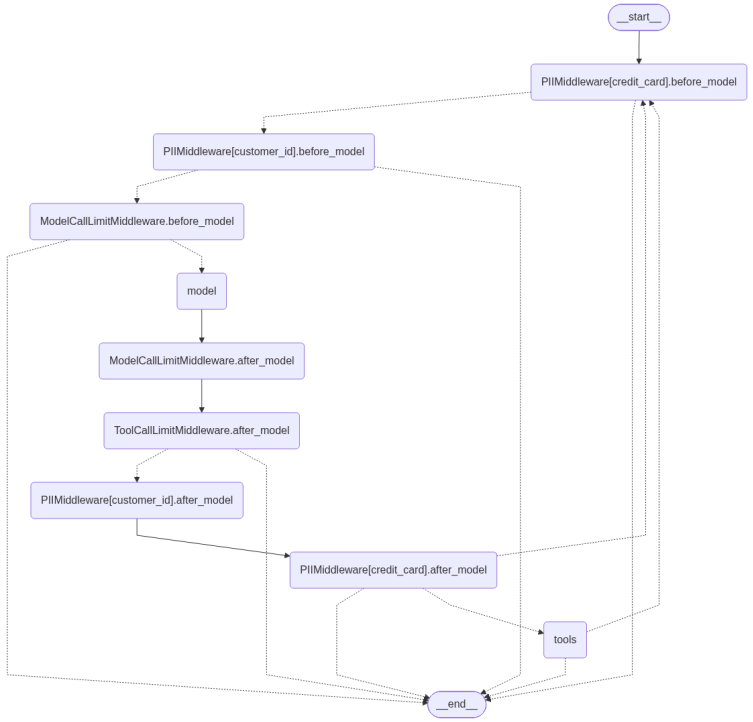
- 오른쪽 두 장: A 에는 `llm_classify` 노드가 없고, C 는 `collect_targets` 에서 점선 분기가 갈린다
- 손으로 그리지 않았다. `build_graph().get_graph()` 출력 그대로다 (`python scripts/render-graph.py` — mermaid PNG · ASCII · mermaid 원문 3종)
- S05 는 설계도(13노드), 이 장은 현재 컴파일되는 그래프(C 8 · A 6)다. 그 차이가 5주차 작업 범위다 — `confidence_gate`·`human_review`·`report`. `rule_promote` 는 이번에 빠져나왔다 (S13). 탐지 3종은 여기 없는 게 맞다 — 그래프 밖의 순수 함수로 두었다 (D-035)
- A 와 C 의 그래프가 다르다는 것이 D-025② 의 근거다. `classifier=None` 이면 노드를 만들지 않는다. 만들어 두고 방문하지 않으면 그림과 실행 경로가 어긋난다
- 코드가 바뀌면 이 그림도 낡는다. mermaid 원문(`.mmd`)을 함께 커밋하고 `python scripts/render-graph.py --check` 로 불일치를 잡는다 (네트워크 불필요)
- PNG 렌더는 mermaid.ink 를 거친다. 전송되는 것은 노드 이름뿐이고 거래 데이터는 포함되지 않는다. 발표장 네트워크에 의존하지 않도록 PNG 를 커밋해 둔다 (D-029)

- **`llm_classify` 안의 Agent 그래프**는 `assets/diagrams/langgraph-agent.png` 에 따로 있다 (`build_classifier(...).agent.get_graph()`). 노드 이름이 길어 슬라이드에 넣으면 읽히지 않으므로 S08 에는 같은 내용을 텍스트로 옮겨 두었다 — 원본이 필요하면 이 파일을 연다



A · 룰만 C · 하이브리드

부록 N-2. llm_classify 안의 Agent 그래프 (실제 렌더)



create_agent 가 만든 그래프 (10노드)

- `build_classifier(...).agent.get_graph()` 출력이다. 손으로 그리지 않았고 `--check` 가 잠근다
- 미들웨어 6노드 + `model` + `tools` + 시작/끝 = 10노드. 가드레일마다 `__end__` 로 가는 점선이 있다
- 라벨에 대괄호가 들어가 LangChain 의 `draw_mermaid()` 출력을 mermaid.ink 가 거절한다. 라벨을 따옴표로 감싸는 emitter 를 `scripts/render-graph.py` 에 따로 뒀다 (D-031)

부록 O. 본편 슬라이드의 보충 근거

S06 State · S07 Node/Edge

- `human_corrections` 를 늦게 넣은 이유 — 생산자도 소비자도 없는 필드가 있으면 상태 정의만 보고 HITL 이 이미 붙어 있다고 읽힌다 (D-025)
- `ReviewState` 를 따로 둔 이유 — 그래야 화면이 검토 큐만으로 같은 서브그래프를 돌리고, 화면과 배치가 다른 코드로 갈라지지 않는다 (D-037)
- Send 병렬을 안 쓴 이유 — 표기 순서가 고정돼야 캐시 히트 수와 호출 수가 결정론이 되고, 그 수치를 발표 지표로 쓴다. 지금 측정 대상은 지연이 아니다

S08 Agent 내부

- 도구 호출 횟수는 **모델이 정한다** — 그래서 표기 하나에 모델 호출이 2회 이상 발생한다
- 가드레일은 문서가 아니라 코드다 — 고객식별정보·카드번호가 섞이면 모델에 닿기 전에 끊기고, 비용 상한도 `run_limit` 으로 들어가 있다

부록 O-2. 본편 슬라이드의 보충 근거 (실측 장)

S13 승격 루프

- 문턱 0.95 에서 승격이 0건이었던 원인은 코드가 아니라 **few-shot 이 0.85~0.9 만 보여준 척도**였다. 155개를 전수 판정해 저장하고 근거별 정밀도를 다시 쟀다
- 모델은 확신이 없으면 **입력 표기를 그대로 대표명으로** 돌려준다. 1부의 실수가 2부 집계로 전이된다 — 이 프로젝트의 주장이 무너지는 자리다
- 두 문턱이 겹치는 구간(0.7~0.8)에서 **사람을 앞에 뒀다** — 뒤집히면 사람이 화면에서 고친 답이 조용히 버려지고 화면은 "반영됨"이라 적는다 (D-037)
- 표기 155 → 115 는 **한 라운드 + 사람 교정 세 줄**의 수다. 자동만 다섯 라운드 돌리면 98 이다

S14 2부 · S15 결과 보존 · S16 효과

- 구독 재현율 56.2% 의 정체 — 넷플릭스가 NETFLIX · 넷플릭스 · NAVERPAY*넷플릭스 로 쪼개져 "최소 3회" 조건을 못 채운다
- 운영 캐시의 후보는 **결과 테이블에 사전 버전을 키로** 넣어 무효화하는 방식이다. 적용은 6주차
- 거래 데이터가 파일에 남지 않는 것은 규제 관점에서 유리하지만 **목표는 재현성이었다**
- 승격 루프가 바꾸는 담당자의 일 — 사전을 전부 채우는 대신 **거래 건수가 많은 항목부터** 본다